



ENES
JURIQUILLA

Bioinformática

I


Licenciatura en Ciencias Genómicas

Profesor: Dr. Wilbert Gutiérrez S

04/Septiembre/2026



Distribución de la clase






ENES-Juriquilla
UNAM

01. Tipos de Secuencias

Parte 2

Profesor: Dr. Wilbert Gutiérrez S

28/Agosto/2026



Formato FASTQ

Identificador — @SRR24043006.1 HWUSI-EAS1571_0037:4:1:1391:1116 length=72
 Secuencia — AATAGNCATCCATTAACGCAGGGGTCCCAACATGCTGCAGGCCATGCCAAGTTAAGAAATCTCAGCGAAGA
 Signo "+" — +
 Scores de calidad — ?;?>:#BBBBDDDDDD:D3:DDDD>D<<DBD3BDB.*<=<7** (7?><6>>>9>>DBDB<D@DDD#####

Identificador — @SRR24043006.2 HWUSI-EAS1571_0037:4:1:11401:1112 length=72
 Secuencia — CAATTNATCCTCCTGAGAACATCACCCCAAGAATTCATTTCATATCTACTATATTATCTAACACCTAGAGA
 Signo "+" — +
 Scores de calidad — CCACA#FFFFGGGEGIIIIIIIIIIIIIIIGIIIIIIIDIIIIHHIIIIIIIIHHIIIIHHFIIIIHHGIGAA

*Se usa como separador entre una secuencia y sus scores de calidad

Base: G
Calidad (Q): 40

Valores de calidad

	0	10	20	30	40
Calidad:	0	10	20	30	40
P_{error} :	1	0.1	0.01	0.001	0.0001

$$P_{\text{error}} = 10^{-Q/10}$$

Actividad 2. Documentar en (Github)


1. Obtener y anotar el valor Q phred score para cada posición de cada nucleótido.
2. Obtener y anotar el promedio para cada posición
3. Graficar el promedio de las posiciones de cada nucleótido.
4. Documentar en Github la actividad e incluir fotografía del ejercicio realizado.

Actividad 2.

1. Obtener y anotar el valor Q phred score para cada posición de cada nucleótido.
2. Obtener y anotar el promedio para cada posición
3. Graficar el promedio de las posiciones de cada nucleótido.
4. Documentar en Github la actividad e incluir fotografía del ejercicio realizado.

```
@NB501590:469:HHFC2BGXH:1:11101:20379:1083 1:N:0:GCTCGGGA+GCGATCTA
ACAGNTAAACTGTAGTNCTG
+
EEEE%EEE6EEEEEEEE$EEE
@NB501590:469:HHFC2BGXH:1:11101:9336:1085 1:N:0:GCTCAGGA+GCGATCTA
TTTCNTCAAATGGTATNGCT
+
EEEE&/EEEE6EE/EE%EAE
@NB501590:469:HHFC2BGXH:1:11101:16721:1087 1:N:0:GCTCAGGA+GCGATCTA
CTATNAATGTCATCTCNAAA
+
AAE<#EEAEEEEEEEE&EEA
@NB501590:469:HHFC2BGXH:1:11101:19490:1087 1:N:0:GCTCAGGA+GCGATCTA
GTTTNTTAGCAAGGAANTAA
+
EAEA)EEEEEEEEEEEE*EEE
@NB501590:469:HHFC2BGXH:1:11101:22332:1088 1:N:0:GCTCAGGA+GCGATCTA
GGGGNTCTGAGCGTACNCT
+
/</(EEAEA<EE//E/</E
```

FastQC



Secuenciamiento del ADN



Byte KB MB GB


Tamaños de información generados con el secuenciamiento

Sistemas Operativos y lenguajes de programación

UNIX



Windows



Mac



GNU/Linux

Supercomputadoras en México



Kan Balam, UNAM. 2007



Aitzaloa, UAM. 2008



Xiucatl, Cinvestav. 2012



Miztli, UNAM. 2013



Abacus, Cinvestav. 2014




LAVIS, UNAM. 2015

Características de Equipo de Supercómputo

- Modelos matemáticos
- Sismología
- Explotación de petróleo
- Predicción de clima
- Energía Nuclear
- Diseño Automotriz
- Control Industrial
- Ciencias Biológicas



Terminal o Shell




Es un programa como cualquier otro. Lo que la hace especial es que su trabajo es ejecutar otros programas, en lugar de realizar cálculos.





25 Basic Linux Commands				
ls	cp	touch	man	sort
pwd	mv	ln	grep	cal
mkdir	rm	cat	echo	whereis
cd	uname	clear	wget	df
rmdir	locate	ps	whoami	wc

Los tres alfabetos



La regla que hay que interiorizar: la T en el archivo es una convención de almacenamiento, no una afirmación sobre la molécula.

Un nucleótido diferente

Symbol	Meaning	Description Origin
G	G	G uanine
A	A	A denine
T	T	T hymine
C	C	C ytosine
R	G or A	pu R ine
Y	T or C	p Y rimidine
M	A or C	a M ino
K	G or T	K etone
S	G or C	S trong interaction
W	A or T	W weak interaction
H	A or C or T	H follows G in alphabet
B	G or T or C	B follows A in alphabet
V	G or C or A	V follows U in alphabet
D	G or A or T	D follows C in alphabet
N	G or A or T or C	a N y

doi:10.1371/journal.pone.0099982.t001

Se pueden encontrar en cuatro lugares: cromatogramas de Sanger en posiciones heterocigotas o de mala calidad, secuencias consenso de una población, primers degenerados, y las corridas de N que marcan huecos en un ensamblaje.



Hebras y complemento reverso

Hebras, complemento reverso y marcos

5'→3'

3'→5'

Reverse complement (5'→3'):

Reverse
Complement

DNA & RNA Sequence Tool

A↔T · G↔C · Watson-Crick pairing
PCR primers · Cloning · Sequencing

Antiparallel strand orientation




De locus a proteínas

El locus genómico

El pre-mRNA

El mRNA maduro

La CDS y proteína



nas

El catálogo en un genoma



01

Secuencias codificantes

02

Secuencias no codificantes

03

Pseudogenes

04


Elementos repetitivos

05

Secuencias reguladoras




Secuencias codificantes

es una parte del ADN que contiene la información necesaria para producir una proteína.




Secuencias no codificantes

Regiones del ADN que no contienen información para producir proteínas, pero pueden cumplir funciones importantes, como regular la expresión de genes o participar en la organización y estabilidad del genoma.




Pseudogenes

Un pseudogén surgió por retrotransposición de un mRNA maduro: se retrotranscribió y se reinsertó en el genoma. Como venía de un mRNA, no tiene intrones, suele traer restos de cola poliA y no tiene promotor. Un pseudogén no procesado surgió por duplicación génica seguida de pérdida de función, así que conserva la estructura de exones e intrones.





Elementos repetitivos

- Los LINE (Long Interspersed Nuclear Elements) son retrotransposones autónomos sin LTR (Long Terminal Repeat).
- Los SINE (Short Interspersed Nuclear Elements) no son autónomos y su familia dominante es Alu (~300pb).
- Los retrotransposones con LTR, incluidos los retrovirus endógenos.
- Los transposones de DNA son cerca del 3% y en humano están prácticamente fosilizados.




Fracciones aproximadas. La detección por homología estima ~50 % de secuencia repetitiva; estimaciones que incluyen elementos muy divergentes llegan a dos tercios (de Koning et al. 2011).



Secuencias reguladoras


- Promotores
- Enhancers
- Silenciadores
- Aisladores

Estas secuencias no tienen un alfabeto propio ni nada que las distinga al mirarlas. Lo único que las convierte en “un enhancer” es una anotación: un intervalo de coordenadas que alguien determinó experimentalmente y guardó en un archivo aparte.



De reads a cromosomas

Los reads son la salida cruda del secuenciador. Los contigs son tramos continuos de consenso contruidos a partir de reads traslapados, sin huecos. Los scaffolds son contigs ordenados y orientados con información de enlace, con huecos de longitud estimada representados como corridas de N. Y los cromosomas son scaffolds ya localizados y orientados en secuencias cromosómicas completas.



Actividad.

Conexión a clúster Ken.

Formato

FASTQ

y

FASTA

```
@A00180:10:H7NK5DMXX:1:1101:16821:1000 1:N:0:GGACTT+GTCGTTCTG
TGCAGCAGCTAATGAGGAACCACTTCCTCCCTCCAGCCGCTCTAAATACCTCAGAACAATAGGATCATCATAATAATCCCCTAGTCTGAACTG
+
8FFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFF
@A00180:10:H7NK5DMXX:1:1101:19090:1016 1:N:0:GGACTT+GTCGTTCTG
TGCAGAAGAAGAAAGCACAGTATTTACGCCTATCCTTCATATTTTCCGCAAGGTAAGTATCTCGGTTTCATATCGAGATTATATAGAATCT
+
FFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFF-FFFFFFFF
@A00180:10:H7NK5DMXX:1:1101:19325:1016 1:N:0:GGACTT+GTCGTTCTG
TGCAGGAAGTTATGCAGGGGCATCCTGTATTATTAAATAGAGCACCTACTCTTCATAGATTAGGTATACAGGCGTTCCAACCTATTTTAGTGG
+
FF-88F8FFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFF-F-FFFFFFF
@A00180:10:H7NK5DMXX:1:1101:30897:1016 1:N:0:GGACTT+GTCGTTCTG
TGCAGAGTACATCAACAAAAGAAACCTAACTGCCCTACCGGCAAACCGGTAGAGTACCCTTCCCCAAAAGTATTACTCCCAGTCAATATAAGG
+
8F888FFF-FFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFFF-FFFFFFFF-FFFFFFFF-FFFFFFFF-FFFFFFFF
```

```
>DLAE000001_TRINITY_DN18_c0_g1_i1
TTTGCTATTGCATCATATGTGAACCTTTGAGGTCCCGGTTTTATCTCCCAGCTACTGAGTT
TAGTGCTTGGGGCGGCCCTGTGAATTTCATACAGTGTTTGTGTTTGTGACTTGCTCTGTG
ACCTGCATATTCAAATGAGGAGGTGGCCATTGTCAAGGACTATGTGGCCTGCCTTAATT
AAGCATAATAATAATTGTGTATGTGGGCTGCTGGTGTGTTTTGTATTGTTGCTTCGACTC
CTTCATTAGTCCACAGTGGGCATTGATAAGCACTTTGTTTTTTTACTGGCATAGGAATGG
AGCAATTATGGGGCGACTCGTTGCCGCTGAAGCCAATTGACTAACTAAAAAATGTATTTG
GTAATGATAACGGCATAAGCATCAAATGAGATCATGTTGCAGAGGGCAAATGAAACAAGA
ACTTTGATTAAAGATACAGAAAGAGGCAATTAAATTATTTTTTGTACATT
>DLAE000002_TRINITY_DN18_c0_g2_i1
CTTGGAGTGGCCCTGCGAGCTTCATAAGGAATGTTTGTAAGTGTCACACTTGTGCTGTGA
CCTGCATATTCAAATGACGAGCAGCCGTCATCAAGGACTATGTGGCCTGCCTTATGAAT
AATGAAAAATGTCTGCTTCCATTCTTCATAAGTTCACGTGGGACAATGATGTACACTTT
GTTTGATTGTCACTGGCATATGGGTGCACTCACTGTGAAATTGGAACCGTTTATTAAGT
TCTATATTCTTTACCATGAATTCCTTGTATATGTTATAAGCTATTATTATAATTTTGAAT
AGAATTTTTTTCAGTGTTTTCTTGATTGAGCGCGCATATCCAGCATTTTACTAGTGATCA
AATAAATATAGGAACATGAGTACTAAGCAGGAGGCTAAGTTGCACCGTCTAGAGATTAGC
ACTCAAGCTACTGGGTTTAGTGGTCCGCAGAGCATTATGGGGAGACCTGTTGCAATGAAG
CCGACCTTCTAAGTATTTAACCTCTCTTTAATTAAATAAATTCTTTTGTGCCT
>DLAE000003_TRINITY_DN18_c1_g1_i1
ACGGGCAAAATTTGAAGAGAGACAGGGGGAGACAATGGGAGAAGATTTTGGATGGTCTG
GCGCAGCGATATGACTGTCACAACAACTTGTACACAATTGTCACAGCAATATGTCACGA
CACACTCGTACACAAAATAATTGTCCAGCTATATGATTGTCCACAACTGGTACACAAT
ATTGTCCCAGCGATATGTCACGACAACTTGTACACAATAATTGTCACAGCGATATGATT
ATCCCAACAACTTGTACACAATAACTGTCCAGCGATATGATTGTCCCAACAACTTGT
ACACAATAACTGTCCAGCGATATGATTGTCCCAACAACTTGTACACAATAACTGTCCC
AGCGATATGATTGTCCCAAC
```

Conexión a

`srun --export=ALL --x11 --pty bash`

