



ENES
JURIQUILLA

Bioinformática

I


Licenciatura en Ciencias Genómicas


Profesor: Dr. Wilbert Gutiérrez S

11/Septiembre/2026




Distribución de la clase






Conexión a cluster KEN



Sesión interactiva



\$srun --export=ALL --x11 --pty bash

comando


exportar todas las
variables del entorno

ejecutar
aplicaciones
gráficas


terminal
interactiva

shell Bash
interactivo

Elegir un estudio publicado



PRJNA750736



SARS-CoV-2

Descargar secuencias crudas

Pasos para descargar secuencias crudas desde el
NCBI:

01

Ingresar al NCBI
<https://www.ncbi.nlm.nih.gov/>

02


Buscar el Bioproject PRJNA750736

03

Elegir SRA experiments

04

Descargar Metadata y Accesion list



Cargar módulo y descargar secuencias

\$module avail


\$module load sra/3.1.1

\$prefetch SRR34860834

\$fastq-dump SRR34860834

***Descargar 5 secuencias aleatorias**






Preguntas

- ¿qué organismo?
- ¿qué tipo de muestra?
- ¿qué plataforma?
- ¿single-end o paired-end?
- ¿cuántos reads?
- ¿cuánto pesa?

Descargar genoma de referencia



Pasos para descargar genoma de referencia desde
el NCBI:

01

Ingresar al NCBI

<https://www.ncbi.nlm.nih.gov/datasets/genome/>

02

Buscar el genoma:

Severe acute respiratory syndrome coronavirus 2

03

Seleccionar el ensamble revisado
ASM985889v3

04

Seleccionar la opción Datasets

05

Copiar Datasets command-line query

Cargar módulo y descargar secuencia



```
$module avail
```

```
$module load ncbi-datasets/18.16
```

```
$datasets download virus genome taxon SARS-CoV-2 -  
-include genome
```

Explorar el formato Fastq y Fasta

```
$less SRR34860834_1.fastq
```


```
$q (salir del visor less)
```

Analizar la calidad de las secuencias descargadas

```
$fastqc *.fastq
```



FastQC




Actividad 1. Explorar secuencias

```
$ ls
$ ls -lh
$ ls -lt
$ file *
$ du -h *
$ du -sh .
$ head -n 20 filename.fastq
$ wc -l filename.fastq
$ wc -l *.fastq | sort
$ grep -c "@SRR" SRR34860834_1.fastq
$ head filename.fasta
```



Jobs con slurm



\$exit

(Confirmar que estamos en directorio de trabajo)

\$cd /mnt/data/bioinfo1/usearname

(Copiar la plantilla de slurm)

\$cp /mnt/data/bioinfo1/wgutierrez/my_script.slurm .

Editar el archivo .slurm y enviar

\$nano my_script.slurm


Editar job_name

Editar mail_user

Editar modulos a usar

Agregar procesos


\$sbatch my_script.slurm





ENES-Juriquilla
UNAM

02. Código genético




Profesor: Dr. Wilbert Gutiérrez S

11/Septiembre/2026

Idea central

Sesenta y cuatro codones, veinte aminoácidos. El reparto podría ser cualquiera, y sin embargo no lo es: la tabla del código genético tiene una estructura que amortigua errores, y esa estructura explica por qué unas sustituciones de aminoácido son toleradas y otras no.



La tabla no es aleatoria

Si el reparto codón a aminoácido fuera un sorteo, no habría patrón alguno. Pero hay dos, y son fuertes.

		Segunda base				
		U	C	A	G	
Primera base	U	UUU F Phe	UCU S Ser	UAU Y Tyr	UGU C Cys	U
		UUC F Phe	UCC S Ser	UAC Y Tyr	UGC C Cys	C
		UUA L Leu	UCA S Ser	UAA –	UGA –	A
		UUG L Leu	UCG S Ser	UAG –	UGG W Trp	G
	C	CUU L Leu	CCU P Pro	CAU H His	CGU R Arg	U
		CUC L Leu	CCC P Pro	CAC H His	CGC R Arg	C
		CUA L Leu	CCA P Pro	CAA Q Gln	CGA R Arg	A
		CUG L Leu	CCG P Pro	CAG Q Gln	CGG R Arg	G
	A	AUU I Ile	ACU T Thr	AAU N Asn	AGU S Ser	U
		AUC I Ile	ACC T Thr	AAC N Asn	AGC S Ser	C
		AUA I Ile	ACA T Thr	AAA K Lys	AGA R Arg	A
		AUG M Met	ACG T Thr	AAG K Lys	AGG R Arg	G
	G	GUU V Val	GCU A Ala	GAU D Asp	GGU G Gly	U
		GUC V Val	GCC A Ala	GAC D Asp	GGC G Gly	C
		GUA V Val	GCA A Ala	GAA E Glu	GGA G Gly	A
		GUG V Val	GCG A Ala	GAG E Glu	GGG G Gly	G

la columna —la segunda base— determina la clase química

■ Hidrofóbico ■ Polar ■ Ácido ■ Básico ■ Especial ■ Paro

Código estándar (tabla 1 del NCBI), vía Biostrings::getGeneticCode(). Los codones se muestran en ARN; en los archivos van con T.

Cómo leer la tabla en su forma cruda

En archivos y en documentación del NCBI van a encontrarse el código escrito así, que es como se guarda de verdad:

AA_s = FFLLSSSSYYCC*WLLLLPPPPHHQQRRRRIIIMTTTTNNKKSSRRVVVAAAADDEEGGGG**

Starts = ---M-----**-*---M-----M-----


Base1 = TTTTTTTTTTTTTTTTCCCCCCCCCCCCCAAAAAAAAAAAAAAAAAAGGGGGGGGGGGGGGGGGGG

Base2 = TTTTCCCCAAAAGGGGTTTTCCCCAAAAGGGGTTTTCCCCAAAAGGGGTTTTCCCCAAAAGGGG

[illegible]


Degeneración

Sesenta y un codones con sentido para veinte aminoácidos. Ese exceso se llama degeneración, y no está repartido parejo.



Inicio y paro

AUG es el codón de inicio canónico y codifica metionina.



Los tres codones de paro son UAA, UAG y UGA. No hay ARNt que los lea; los reconocen proteínas llamadas factores de liberación.

Inicio y paro

Evidencia

Tiene ATG

Tiene ATG + STOP

ORF larga

Evidencia de expresión

Homología con proteínas conocidas

Dominio proteico conservado

Conservación evolutiva

Varias evidencias independientes

Confianza

Baja

Baja-moderada

Moderada

Moderada-alta

Alta

Alta

Alta

Muy alta



El código no es universal

Se le llamó “código universal” durante años y el nombre pegó. Es falso. El NCBI mantiene actualmente 33 tablas de traducción distintas, numeradas del 1 al 33 con huecos, y la lista sigue creciendo.

mitocondria de vertebrados

		Segunda base								
		U		C		A		G		
U	UUU	F	UCU	S	UAU	Y	UGU	C		
	UUC	F	UCC	S	UAC	Y	UGC	C		
	UUA	L	UCA	S	UAA	–	UGA	–		
	UUG	L	UCG	S	UAG	–	UGG	W		
C	CUU	L	CCU	P	CAU	H	CGU	R		
	CUC	L	CCC	P	CAC	H	CGC	R		AGA Arg → Paro
	CUA	L	CCA	P	CAA	Q	CGA	R		
	CUG	L	CCG	P	CAG	Q	CGG	R		AGG Arg → Paro
A	AUU	I	ACU	T	AAU	N	AGU	S		AUA Ile → Met
	AUC	I	ACC	T	AAC	N	AGC	S		
	AUA	I	ACA	T	AAA	K	AGA	R		UGA Paro → Trp
	AUG	M	ACG	T	AAG	K	AGG	R		
G	GUU	V	GCU	A	GAU	D	GGU	G		
	GUC	V	GCC	A	GAC	D	GGC	G		
	GUA	V	GCA	A	GAA	E	GGA	G		
	GUG	V	GCG	A	GAG	E	GGG	G		

Tabla 2 del NCBI. Existen 33 tablas de traducción. Las 60 casillas restantes son idénticas a la estándar.

Diferencias calculadas comparando las tablas 1 y 2 del NCBI vía Biostrings, no transcritas a mano.

Cómo se descifró





- En 1958 Crick propuso que debía existir una molécula adaptadora entre el ácido nucleico y el aminoácido, algo que tradujera de un alfabeto al otro.
- El 27 de mayo de 1961, a las tres de la mañana, Heinrich Matthaei corrió el experimento que rompió el problema. Con Marshall Nirenberg había montado un sistema libre de células de E. coli, y le agregó poli-U, un ARN sintético de puros uracilos. El sistema produjo polifenilalanina. El tubo con fenilalanina marcada dio 38,000 cuentas por miligramo contra 70 del control. UUU codifica Phe, y era la primera palabra del diccionario.
- Los cinco años siguientes fueron llenar la tabla. Har Gobind Khorana sintetizó ARN de secuencia definida y Nirenberg desarrolló un ensayo de unión de tripletes; entre los dos métodos, para 1966 los 64 codones estaban asignados. Robert Holley, por su lado, determinó la estructura del ARNt de alanina de levadura, que fue el primer ácido nucleico secuenciado completo, y con eso apareció la molécula adaptadora que Crick había postulado.

Los tres compartieron el Nobel en 1968.

Segunda letra	
C	A
CU	UAU Tyr
CC	UAC (Y)
CA	UAA Término
CG	UAG Término
CU	CAU His
CC	CAC (H)
CA	CAA Gln
CG	CAG (Q)
CU	AAU Asn
CC	AAC (N)
CA	AAA Lys
CG	AAG (K)
CU	GAU Asp
CC	GAC (D)
CA	GAA Glu
CG	GAG (E)

De dónde salió el código

- La primera es de Crick, en 1968, y se llama accidente congelado. Las asignaciones fueron arbitrarias en origen, pero una vez establecidas quedaron atrapadas.
- La segunda dice que el código fue seleccionado para minimizar errores. Acá sí hay números. En 1998, Freeland y Hurst generaron códigos alternativos al azar y midieron cuánto daño causa una mutación en cada uno.
- La tercera hipótesis es estereoquímica: habría afinidades químicas directas entre cada aminoácido y sus codones, y esas afinidades fijaron las asignaciones.
- La cuarta es de coevolución: el código creció junto con las rutas de síntesis de aminoácidos, y los aminoácidos que aparecieron después heredaron codones de sus precursores metabólicos.



Th

Ar


Cy

V

Sc


Cuando el ribosoma hace trampa

- La selenocisteína es el aminoácido 21. Se inserta en un UGA cuando el ARNm tiene corriente abajo una estructura llamada elemento SECIS, una horquilla que le indica al ribosoma que ese paro en particular no es paro. La pirrolisina es el 22 y se inserta en un UAG en ciertas arqueas metanogénicas.
- Está también el readthrough, en el que el ribosoma simplemente ignora un codón de paro con cierta frecuencia y sigue traduciendo, algo común en virus.



Por qué esto importa en bioinformática

- Traducción en seis marcos.
- Comparar proteína detecta homología más lejana que comparar nucleótido.
- Sinónimo contra no sinónimo: dN/dS
- Cuánto mide un ORF por azar.
- Cómo alinear secuencias codificantes.



Actividad 2. Nucleótidos a ORFs

1. Dada la secuencia de nucleotidos obtener la secuencia del ORFs.
2. Revisar cuales son los marcos de lecturas obtenidos e identificarlos en la secuencia de la hoja impresa.

Quiz_3_ENES



11 de septiembre de 2026