



ENES
JURIQUILLA

Bioinformática

I


Licenciatura en Ciencias Genómicas


Profesor: Dr. Wilbert Gutiérrez S

18/Septiembre/2026




Distribución de la clase





Conexión a cluster KEN

- Revisión de ruta correcta
- Borrar descargas anteriores SRR*



Actividad 1.

- **Descargar mediante SLURM las primeras 10 secuencias del siguiente Bioproject.**
- **Descargar el genoma de referencia junto con el cds y protein.**


1. Usar la plantilla de Slurm y enviar para que inicie el proceso.

**Número
Bioproject**

**Genoma
ensamblado**



PRJNA295606



E. coli

**Genome assembly
ASM886v2**


Quiz_4_ENES

Dar tiempo para explorar archivos y realizar Quiz

18 de septiembre de 2026



Código genético



La tabla no es aleatoria

Si el reparto codón a aminoácido fuera un sorteo, no habría patrón alguno. Pero hay dos, y son fuertes.

		Segunda base												
		U	C	A	G									
Primera base	U	UUU	F	Phe	UCU	S	Ser	UAU	Y	Tyr	UGU	C	Cys	U
		UUC	F	Phe	UCC	S	Ser	UAC	Y	Tyr	UGC	C	Cys	C
		UUA	L	Leu	UCA	S	Ser	UAA	—		UGA	—		A
		UUG	L	Leu	UCG	S	Ser	UAG	—		UGG	W	Trp	G
	C	CUU	L	Leu	CCU	P	Pro	CAU	H	His	CGU	R	Arg	U
		CUC	L	Leu	CCC	P	Pro	CAC	H	His	CGC	R	Arg	C
		CUA	L	Leu	CCA	P	Pro	CAA	Q	Gln	CGA	R	Arg	A
		CUG	L	Leu	CCG	P	Pro	CAG	Q	Gln	CGG	R	Arg	G
	A	AUU	I	Ile	ACU	T	Thr	AAU	N	Asn	AGU	S	Ser	U
		AUC	I	Ile	ACC	T	Thr	AAC	N	Asn	AGC	S	Ser	C
		AUA	I	Ile	ACA	T	Thr	AAA	K	Lys	AGA	R	Arg	A
		AUG	M	Met	ACG	T	Thr	AAG	K	Lys	AGG	R	Arg	G
	G	GUU	V	Val	GCU	A	Ala	GAU	D	Asp	GGU	G	Gly	U
		GUC	V	Val	GCC	A	Ala	GAC	D	Asp	GGC	G	Gly	C
		GUA	V	Val	GCA	A	Ala	GAA	E	Glu	GGA	G	Gly	A
		GUG	V	Val	GCG	A	Ala	GAG	E	Glu	GGG	G	Gly	G


la columna —la segunda base— determina la clase química

■ Hidrofóbico ■ Polar ■ Ácido ■ Básico ■ Especial ■ Paro

Código estándar (tabla 1 del NCBI), vía Biostrings::getGeneticCode(). Los codones se muestran en ARN; en los archivos van con T.

Inicio y paro

AUG es el codón de inicio canónico y codifica metionina.



Los tres codones de paro son UAA, UAG y UGA. No hay ARNt que los lea; los reconocen proteínas llamadas factores de liberación.

El código no es universal

Se le llamó “código universal” durante años y el nombre pegó. Es falso. El NCBI mantiene actualmente 33 tablas de traducción distintas, numeradas del 1 al 33 con huecos, y la lista sigue creciendo.

mitocondria de vertebrados

		Segunda base								
		U		C		A		G		
Primera base	U	UUU	F	UCU	S	UAU	Y	UGU	C	
		UUC	F	UCC	S	UAC	Y	UGC	C	
		UUA	L	UCA	S	UAA	–	UGA	–	
		UUG	L	UCG	S	UAG	–	UGG	W	
	C	CUU	L	CCU	P	CAU	H	CGU	R	AGA Arg → Paro AGG Arg → Paro
		CUC	L	CCC	P	CAC	H	CGC	R	
		CUA	L	CCA	P	CAA	Q	CGA	R	
		CUG	L	CCG	P	CAG	Q	CGG	R	
	A	AUU	I	ACU	T	AAU	N	AGU	S	AUA Ile → Met UGA Paro → Trp
		AUC	I	ACC	T	AAC	N	AGC	S	
		AUA	I	ACA	T	AAA	K	AGA	R	
		AUG	M	ACG	T	AAG	K	AGG	R	
G	GUU	V	GCU	A	GAU	D	GGU	G		
	GUC	V	GCC	A	GAC	D	GGC	G		
	GUA	V	GCA	A	GAA	E	GGA	G		
	GUG	V	GCG	A	GAG	E	GGG	G		

Tabla 2 del NCBI. Existen 33 tablas de traducción. Las 60 casillas restantes son idénticas a la estándar.

Diferencias calculadas comparando las tablas 1 y 2 del NCBI vía Biostrings, no transcritas a mano.



ORFs de una secuencia

>Secuencia_ejemplo

```
ATGGTGCACCTGACTCCTGAGGAGAAGTCTGCCGTTACTGCCCTGTGGGGCAAGGT  
GAACGTGGATGAAGTTGGTGGTGAGGCCCTGGGCAGGCTGCTGGTGGTCTACCCTT  
GGACCCAGAGGTTCTTTGAGTCCTTTGGGGATCTGTCCACTCCTGATGCTGTTATGG  
GCAACCCTAAGGTGAAGGCTCATGGCAAGAAAGTGCTCGGTGCCTTTAGTGATGGC  
CTGGCTCACCTGGACAACCTCAAGGGCACCTTTGCCACACTGAGTGAGCTGCACTG  
TGACAAGCTGCACGTGGATCCTGAGAACTTCAGGCTCCTGGGCAACGTGCTGGTCT  
GTGTGCTGGCCCATCACTTTGGCAAAGAATTCACCCCACCAGTGCAGGCTGCCTATC  
AGAAAGTGGTGGCTGGTGTGGCTAATGCCCTGGCCCACAAGTATCACTAA
```



Resultado

>|c|ORF1

MVHLTPEEKSAVTALWGKVVNVDEVGGGEALGRLLVVYPWTQRFFESFGDLS
TPDAVMGNPKVKAHGKKVLGAFSDGLAHL DNLKGT FATLSELHCDKLHVD
PENFRLLGNVLVCVLAHHFGKEFTPPVQAAYQKVVAGVANALAHKYH



Blastp

>|cl|ORF1


MVHLTPEEKSAVTALWGKVNVDEVGGEALGRLLVVYPWTQRFFESFGDLS
TPDAVMGNPKVKAHGKKVLGAFSDGLAHLDNLKGTFATLSELHCDKLHVD
PENFRLLGNVLVCVLAHHFGKEFTPPVQAAYQKVVAGVANALAHKYH



Modelo 3D protein

HbA (normal hemoglobin)

Sickle hemoglobin (HbS).



G	0	-2	0	-1	-3	-2	-2	6		6	-3	-4	0	-2	0	0	0	0	0	2	-2	H
H	-2	0	1	-1	-3	0	0	-2	8		4	0	-3	2	0	-2	-3	0	0	-3	2	I
I	-1	-3	-3	-3	-1	-3	-3	-4	-3	4		4	-4	0	0	-3	-4	-3	0	-4	0	L
L	-1	-2	-3	-4	-1	-2	-3	-4	-3	2	4		4	-2	-4	-1	-2	0	0	-3	-4	K
K	-1	2	0	-1	-3	1	1	-2	-1	-3	-2	5		6	0	-3	-3	-2	0	-3	2	M

Matrices de sustitución (PAM y BLOSUM)

Modelando la evolución de las
proteínas para comparar secuencias

Secuencia 1: A C G T A C

Secuencia 2: A C G A A C

Sustitución de aminoácidos

Si dos proteínas tienen aminoácidos diferentes en una posición,
¿cómo sabemos si esa sustitución es “razonable”?

Proteína 1: A L G K E M V ...

Proteína 2: A L G R E M V ...

↑

K → R

¿K→R debería tener la misma penalización que K→W?

¿Todas las sustituciones de aminoácidos son igual de probables?

¿Cómo podríamos cuantificar esa “similitud” biológica?

Idea clave: una matriz de sustitución asigna un puntaje a cada posible
reemplazo de aminoácido.

E	E	V	N	A	L	K
E	E	V	K	T	L	K
K	E	V	E	E	L	A
K	E	V	E	E	L	A
K	E	V	E	E	L	A
K	E	V	E	E	L	A
E	E	V	D	A	I	V
E	E	V	D	E	L	V
Q	E	V	A	E	L	V
E	L	V	N	E	I	T
E	I	V	S	E	L	A
D	F	V	K	N	L	E

De alineamiento a puntuaciones

```
SEQ1  M A L W K T G
SEQ2  M A L F K - G
      | | | | |
```


Para evaluar un alineamiento necesitamos puntuar:

coincidencias

sustituciones

inserciones/deleciones

Las propiedades fisicoquímicas y la historia evolutiva hacen que ciertas sustituciones sean mucho más frecuentes que otras.



BLOSUM = BLOcks SUBstitution Matrix

Henikoff & Henikoff 1992

Un número alto (ej. BLOSUM80) se usa para secuencias muy similares, mientras que un número bajo (ej. BLOSUM45 o BLOSUM62, que es la estándar por defecto) es ideal para detectar relaciones más distantes.

BLOSUM62

	A	R	N	D	C	Q	E	G	H	I	L	K	M	F	P	S	T	W	Y	V
A	4	-1	-2	-2	0	-1	-1	0	-2	-1	-1	-1	-1	-2	-1	1	0	-3	-2	0
R	-1	5	0	-2	-3	1	0	-2	0	-3	-2	2	-1	-3	-2	-1	-1	-3	-2	-3
N	-2	0	6	1	-3	0	0	0	1	-3	-3	0	-2	-3	-2	1	0	-4	-2	-3
D	-2	-2	1	6	-3	0	2	-1	-1	-3	-4	-1	-3	-3	-1	0	-1	-4	-3	-3
C	0	-3	-3	-3	9	-3	-4	-3	-3	-1	-1	-3	-1	-2	-3	-1	-1	-2	-2	-1
Q	-1	1	0	0	-3	5	2	-2	0	-3	-2	1	0	-3	-1	0	-1	-2	-1	-2
E	-1	0	0	2	-4	2	5	-2	0	-3	-3	1	-2	-3	-1	0	-1	-3	-2	-2
G	0	-2	0	-1	-3	-2	-2	6	-2	-4	-4	-2	-3	-3	-2	0	-2	-2	-3	-3
H	-2	0	1	-1	-3	0	0	-2	8	-3	-3	-1	-2	-1	-2	-1	-2	-2	2	-3
I	-1	-3	-3	-3	-1	-3	-3	-4	-3	4	2	-3	1	0	-3	-2	-1	-3	-1	3
L	-1	-2	-3	-4	-1	-2	-3	-4	-3	2	4	-2	2	0	-3	-2	-1	-2	-1	1
K	-1	2	0	-1	-3	1	1	-2	-1	-3	-2	5	-1	-3	-1	0	-1	-3	-2	-2
M	-1	-1	-2	-3	-1	0	-2	-3	-2	1	2	-1	5	0	-2	-1	-1	-1	-1	1
F	-2	-3	-3	-3	-2	-3	-3	-3	-1	0	0	-3	0	6	-4	-2	-2	1	3	-1
P	-1	-2	-2	-1	-3	-1	-1	-2	-2	-3	-3	-1	-2	-4	7	-1	-1	-4	-3	-2
S	1	-1	1	0	-1	0	0	0	-1	-2	-2	0	-1	-2	-1	4	1	-3	-2	-2
T	0	-1	0	-1	-1	-1	-1	-2	-2	-1	-1	-1	-1	-2	-1	1	5	-2	-2	0
W	-3	-3	-4	-4	-2	-2	-3	-2	-2	-3	-2	-3	-1	1	-4	-3	-2	11	2	-3
Y	-2	-2	-2	-3	-2	-1	-2	-3	2	-1	-1	-2	-1	3	-3	-2	-2	2	7	-1
V	0	-3	-3	-3	-1	-2	-2	-3	-3	3	1	-2	1	-1	-2	-2	0	-3	-1	4

PAM = Point Accepted Mutation

Dayhoff, 1978

Un número bajo de PAM (ej. PAM30) sirve para secuencias muy parecidas; un número alto (ej. PAM250) se usa para distancias evolutivas grandes.

	A	R	N	D	C	Q	E	G	H	I	L	K	M	F	P	S	T	W	Y	V	B	J	Z	X
A	2	-2	0	0	-2	0	0	1	-1	-1	-2	-1	-1	-3	1	1	1	-6	-3	0	0	-1	0	-1
R	-2	6	0	-1	-4	1	-1	-3	2	-2	-3	3	0	-4	0	0	-1	2	-4	-2	-1	-3	0	-1
N	0	0	2	2	-4	1	1	0	2	-2	-3	1	-2	-3	0	1	0	-4	-2	-2	2	-3	1	-1
D	0	-1	2	4	-5	2	3	1	1	-2	-4	0	-3	-6	-1	0	0	-7	-4	-2	3	-3	3	-1
C	-2	-4	-4	-5	12	-5	-5	-3	-3	-2	-6	-5	-5	-4	-3	0	-2	-8	0	-2	-4	-5	-5	-1
Q	0	1	1	2	-5	4	2	-1	3	-2	-2	1	-1	-5	0	-1	-1	-5	-4	-2	1	-2	3	-1
E	0	-1	1	3	-5	2	4	0	1	-2	-3	0	-2	-5	-1	0	0	-7	-4	-2	3	-3	3	-1
G	1	-3	0	1	-3	-1	0	5	-2	-3	-4	-2	-3	-5	0	1	0	-7	-5	-1	0	-4	0	-1
H	-1	2	2	1	-3	3	1	-2	6	-2	-2	0	-2	-2	0	-1	-1	-3	0	-2	1	-2	2	-1
I	-1	-2	-2	-2	-2	-2	-2	-3	-2	5	2	-2	2	1	-2	-1	0	-5	-1	4	-2	3	-2	-1
L	-2	-3	-3	-4	-6	-2	-3	-4	-2	2	6	-3	4	2	-3	-3	-2	-2	-1	2	-3	5	-3	-1
K	-1	3	1	0	-5	1	0	-2	0	-2	-3	5	0	-5	-1	0	0	-3	-4	-2	1	-3	0	-1
M	-1	0	-2	-3	-5	-1	-2	-3	-2	2	4	0	6	0	-2	-2	-1	-4	-2	2	-2	3	-2	-1
F	-3	-4	-3	-6	-4	-5	-5	-5	-2	1	2	-5	0	9	-5	-3	-3	0	7	-1	-4	2	-5	-1
P	1	0	0	-1	-3	0	-1	0	0	-2	-3	-1	-2	-5	6	1	0	-6	-5	-1	-1	-2	0	-1
S	1	0	1	0	0	-1	0	1	-1	-1	-3	0	-2	-3	1	2	1	-2	-3	-1	0	-2	0	-1
T	1	-1	0	0	-2	-1	0	0	-1	0	-2	0	-1	-3	0	1	3	-5	-3	0	0	-1	-1	-1
W	-6	2	-4	-7	-8	-5	-7	-7	-3	-5	-2	-3	-4	0	-6	-2	-5	17	0	-6	-5	-3	-6	-1
Y	-3	-4	-2	-4	0	-4	-4	-5	0	-1	-1	-4	-2	7	-5	-3	-3	0	10	-2	-3	-1	-4	-1
V	0	-2	-2	-2	-2	-2	-2	-1	-2	4	2	-2	2	-1	-1	-1	0	-6	-2	4	-2	2	-2	-1
B	0	-1	2	3	-4	1	3	0	1	-2	-3	1	-2	-4	-1	0	0	-5	-3	-2	3	-3	2	-1
J	-1	-3	-3	-3	-5	-2	-3	-4	-2	3	5	-3	3	2	-2	-2	-1	-3	-1	2	-3	5	-2	-1
Z	0	0	1	3	-5	3	3	0	2	-2	-3	0	-2	-5	0	0	-1	-6	-4	-2	2	-2	3	-1
X	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1

PAM250

Formato FASTA

FASTA es el formato más usado de la biología molecular y no tiene una especificación formal.

marca de inicio
de registro

identificador
(hasta el primer espacio)

descripción libre, sin reglas

```
>NC_001416.1 Enterobacteria phage lambda, complete genome
```

```
GGGCGGCGACCTCGCGGGTTTTCGCTATTTATGAAAATTTTCCGGTTTAAGGCGTTTCCGTTCTTCTTCG
```

```
TCATAACTTAATGTTTTTATTTAAAATACCCTCTGAAAAGAAAGGAAACGACAGGTGCTGAAAGCGAGGC
```

```
TTTTTGGCCTCTGTCGTTTCCTTTCTCTGTTTTTGTCGGTGGAATGAACAATGGAAGTCAACAAAAGCA
```

70 caracteres por línea, por convención, no por norma



Diferentes encabezados

NCBI actual

```
>NC_001416.1 Escherichia virus Lambda, complete genome
```

UniProt

```
>sp|P01013|OVAX_CHICK.Ovalbumin-related protein X OS=Gallus gallus OX=9031 PE=1 SV=2
```

NCBI histórico
(GI, retirado en 2016)

```
>gi|129295|sp|P01013|OVAX_CHICK ◀ sin espacio
```

Ensembl

```
>ENST00000456328.2 cdna chromosome:GRCh38:1:11869:14409:1 gene:ENSG00000290825.1
```

hecho a mano

```
>mi_secuencia_favorita ◀ sin espacio
```

por convención, el identificador termina aquí: en el primer espacio
sin espacio: el identificador es el encabezado entero



identificador



campos clave=valor



descripción libre



número GI (retirado)

Diferentes extensiones

.fasta y .fa son genéricas. El NCBI usa un esquema más fino: .fna para ácidos nucleicos, .faa para aminoácidos, .ffn para regiones codificantes en nucleótidos, .frn para RNAs. Existen .fsa, .mfa, .fas y otras.

En la práctica se usan cuatro: .fa, .fasta, .fna, .faa.



Explorar el archivo fasta o fna

```
>NC_002695.2 Escherichia coli O157:H7 str. Sakai DNA, complete genome
AGCTTTTCATTCTGACTGCAACGGGCAATATGTCTCTGTGTGGATTAAAAAAAGAGTCTCTGACAGCAGCTTCTGAACTG
GTTACCTGCCGTGAGTAAATTTAAATTTTATTGACTTAGGTCACTAAATACTTTAACCAATATAGGCATAGCGCACAGAC
AGATAAAAATTACAGAGTACACAACATCCATGAAACGCATTAGCACCACCATTACCACCACCATCACCACCACCATCACC
ATTACCATTACCACAGGTAACGGTGCGGGCTGACGCGTACAGGAAACACAGAAAAAAGCCCGCACCTGACAGTGCGGGCT
TTTTTTTTCGACCAAAGGTAACGAGGTAACAACCATGCGAGTGTTGAAGTTCGGCGGTACATCAGTGGCAAATGCAGAACG
TTTTCTGCGGGTTGCCGATATTCTGGAAAGCAATGCCAGGCAGGGGCAGGTGGCCACCGTCCTCTCTGCCCCCGCCAAA
TCACCAACCACCTGGTGGCGATGATTGAAAAAACCATTAGCGGCCAGGATGCTTTACCCAATATCAGCGATGCCGAACGT
ATTTTGGCCGA ACTTCTGACGGGACTCGCCGCCGCCAGCCGGGATTCCCGCTGGCGCAATTGAAA ACTTTCGTCGACCA
GGAATTTGCCCAAATAAAACATGTCCTGCATGGCATTAGTTTGTTAGGGCAGTGCCCGGATAGCATTAAACGCTGCGCTGA
TTTGCCGTGGCGAGAAAATGTCGATCGCCATTATGGCCGGCGTATTAGAAGCGCGCGGT CACAACGTTACCGTTATCGAT
CCGGTCGAAAAACTGCTGGCAGTGGGGCATTACCTCGAATCTACTGTCGATATTGCAGAGTCCACCCGCCGTATTGCGGC
AAGTCGTATTCCGGCTGATCACATGGTGCTGATGGCAGGTTTCACCGCCGGTAATGAAAAAGGCGAACTGGTGGTACTTG
GACGCAACGGTTCCGACTACTCCGCGGCGGTGCTGGCTGCCTGTTTACGCGCCGATTGTTGCGAGATTTGGACGGACGTT
```

Lo único que todo el mundo respeta:

- Un registro empieza con una línea que abre con >.
- La secuencia va en las líneas siguientes.
- El registro termina cuando aparece otro > o se acaba el archivo.

Actividad 2.

- **Explorar el ensamble del genoma de *E. coli*, descargado al inicio de la sesión.**

1. ¿Cuál es el identificador del genoma ensamblado?
2. ¿Cuántas secuencias contiene el archivo?

Actividad 2. Explorar las secuencias del ensamble, cds y proteina.

```
$ head -n 3 GC*.fna
```

```
$ grep -c "^>" *
```

```
$ wc -l GC*.fna
```



Quiz_5_ENES

Dar tiempo para explorar archivos y realizar Quiz

18 de septiembre de 2026

