



ENES
JURIQUILLA

Bioinformática

I


Licenciatura en Ciencias Genómicas


Profesor: Dr. Wilbert Gutiérrez S

25/Septiembre/2026




Distribución de la clase





Inicio de exámenes



Actividad 1.

- **Eliminar todos los SRR* que tengan de otros ejercicios anteriores.**
- **Descargar mediante job de SLURM todas las secuencias del siguiente Bioproject.**
- **Descargar el genoma, cds y protein de referencia, que sea adecuado para el organismo de origen de las secuencias crudas.**

1. Usar la plantilla de Slurm y enviar para que inicie el proceso.

**Número
Bioproject**

**Genoma
ensamblado**



PRJNA268110



organism?

Genome assembly?


Actividad 1.

- **Matrices.**

1. Cada estudiante creará una secuencia de 15 nucleótidos que no codifique a codones de inicio y paro.
2. Escribir/obtener la secuencia de aminoácidos.
3. Cada estudiante provocará una o dos sustituciones de nucleótidos en la secuencia de otro compañero.
4. Escribir/obtener nuevamente la secuencia de aminoácidos con la mutación.
5. Mediar la puntuación con BLOSUM y PAM.
6. Gana quién provoque el mayor valor de divergencia.

Continuidad

Examen



Cambios mutacionales

- Mutación silenciosa: cambia el codón, pero no cambia el aminoácido.
- Mutación missense: cambia el aminoácido.
- Mutación nonsense: genera un codón de paro.

EEVNAALK
EEVKTLK
KEVEELAA
KEVEELAA
KEVEELAA
KEVEELAA
EEVDAAIV
EEVDLVL
QEVAE LVL
ELVNEIT
EIVSELAA
DFVKNLE

G	0	-2	0	-1	-3	-2	-2	6		6	-3	-4	0	-2	0	0	0	0	0	2	-2	H
H	-2	0	1	-1	-3	0	0	-2	8		4	0	-3	2	0	-2	-3	0	0	-3	2	I
I	-1	-3	-3	-3	-1	-3	-3	-4	-3	4		4	-4	0	0	-3	-4	-3	0	-4	0	L
L	-1	-2	-3	-4	-1	-2	-3	-4	-3	2	4		4	-2	-4	-1	-2	0	0	-3	-4	K
K	-1	2	0	-1	-3	1	1	-2	-1	-3	-2	5		6	0	-3	-3	-2	0	-3	2	M

Matrices de sustitución (PAM y BLOSUM)

Modelando la evolución de las
proteínas para comparar secuencias

Secuencia 1: A C G T A C

Secuencia 2: A C G A A C

Sustitución de aminoácidos

Si dos proteínas tienen aminoácidos diferentes en una posición,
¿cómo sabemos si esa sustitución es “razonable”?

Proteína 1: A L G K E M V ...

Proteína 2: A L G R E M V ...

↑


K → R

¿K→R debería tener la misma penalización que K→W?

¿Todas las sustituciones de aminoácidos son igual de probables?

¿Cómo podríamos cuantificar esa “similitud” biológica?

Idea clave: una matriz de sustitución asigna un puntaje a cada posible
reemplazo de aminoácido.



E	V	N	A	L	K
E	V	K	T	L	K
K	E	V	E	E	L
K	E	V	E	E	L
K	E	V	E	E	L
K	E	V	E	E	L
E	E	V	D	A	I
E	E	V	D	E	L
Q	E	V	A	E	L
E	L	V	N	E	I
E	I	V	S	E	L
D	F	V	K	N	L

De alineamiento a puntuaciones

```
SEQ1  M A L W K T G
SEQ2  M A L F K - G
      | | | | |
```

Para evaluar un alineamiento necesitamos puntuar:

- Coincidencias
- Sustituciones
- Inserciones/deleciones

Las propiedades fisicoquímicas y la historia evolutiva hacen que ciertas sustituciones sean mucho más frecuentes que otras.

EEVNAALK
EEVKTLK
KEVEELAL
KEVEELAL
KEVEELAL
KEVEELAL
EEVDIV
EEVDLVL
QEVAEVLV
ELVNEIT
EIVSELAL
DFVKNLE

La respuesta: log-odds

$$\log(\text{odds}) = \log\left(\frac{p}{1-p}\right)$$

“logit function”
The log of the ratio of the probabilities
→ The basis of logistic regression

q_{ij} es la frecuencia con la que el par i con j aparece alineado en alineamientos que sabemos que son de proteínas homólogas. Es lo que de verdad se observa cuando dos secuencias comparten ancestro.


$p_i \cdot p_j$ es la frecuencia con la que ese par aparecería si los dos residuos fueran independientes, cada uno apareciendo a su frecuencia de fondo en las proteínas. Es lo que se esperaría por pura casualidad.

EEVNAALK
EEVKTKL
KEVEELAL
KEVEELAL
KEVEELAL
KEVEELAL
EEVDALIV
EEVDLVL
QEVAE LVL
ELVNEIT
EIVSELAL
DFVKNLE

BLOSUM = BLOcks SUbstitution Matrix

Henikoff & Henikoff 1992

Un número alto (ej. BLOSUM80) se usa para secuencias muy similares, mientras que un número bajo (ej. BLOSUM45 o BLOSUM62, que es la estándar por defecto) es ideal para detectar relaciones más distantes.




BLOSUM62

	A	R	N	D	C	Q	E	G	H	I	L	K	M	F	P	S	T	W	Y	V
A	4	-1	-2	-2	0	-1	-1	0	-2	-1	-1	-1	-1	-2	-1	1	0	-3	-2	0
R	-1	5	0	-2	-3	1	0	-2	0	-3	-2	2	-1	-3	-2	-1	-1	-3	-2	-3
N	-2	0	6	1	-3	0	0	0	1	-3	-3	0	-2	-3	-2	1	0	-4	-2	-3
D	-2	-2	1	6	-3	0	2	-1	-1	-3	-4	-1	-3	-3	-1	0	-1	-4	-3	-3
C	0	-3	-3	-3	9	-3	-4	-3	-3	-1	-1	-3	-1	-2	-3	-1	-1	-2	-2	-1
Q	-1	1	0	0	-3	5	2	-2	0	-3	-2	1	0	-3	-1	0	-1	-2	-1	-2
E	-1	0	0	2	-4	2	5	-2	0	-3	-3	1	-2	-3	-1	0	-1	-3	-2	-2
G	0	-2	0	-1	-3	-2	-2	6	-2	-4	-4	-2	-3	-3	-2	0	-2	-2	-3	-3
H	-2	0	1	-1	-3	0	0	-2	8	-3	-3	-1	-2	-1	-2	-1	-2	-2	2	-3
I	-1	-3	-3	-3	-1	-3	-3	-4	-3	4	2	-3	1	0	-3	-2	-1	-3	-1	3
L	-1	-2	-3	-4	-1	-2	-3	-4	-3	2	4	-2	2	0	-3	-2	-1	-2	-1	1
K	-1	2	0	-1	-3	1	1	-2	-1	-3	-2	5	-1	-3	-1	0	-1	-3	-2	-2
M	-1	-1	-2	-3	-1	0	-2	-3	-2	1	2	-1	5	0	-2	-1	-1	-1	-1	1
F	-2	-3	-3	-3	-2	-3	-3	-3	-1	0	0	-3	0	6	-4	-2	-2	1	3	-1
P	-1	-2	-2	-1	-3	-1	-1	-2	-2	-3	-3	-1	-2	-4	7	-1	-1	-4	-3	-2
S	1	-1	1	0	-1	0	0	0	-1	-2	-2	0	-1	-2	-1	4	1	-3	-2	-2
T	0	-1	0	-1	-1	-1	-1	-2	-2	-1	-1	-1	-1	-2	-1	1	5	-2	-2	0
W	-3	-3	-4	-4	-2	-2	-3	-2	-2	-3	-2	-3	-1	1	-4	-3	-2	11	2	-3
Y	-2	-2	-2	-3	-2	-1	-2	-3	2	-1	-1	-2	-1	3	-3	-2	-2	2	7	-1
V	0	-3	-3	-3	-1	-2	-2	-3	-3	3	1	-2	1	-1	-2	-2	0	-3	-1	4

PAM = Point Accepted Mutation

Dayhoff, 1978

Un número bajo de PAM (ej. PAM30) sirve para secuencias muy parecidas; un número alto (ej. PAM250) se usa para distancias evolutivas grandes.



PAM250


[illegible]

BLOSUM

Henikoff & Henikoff 1992

		alifáticos y aromáticos								pequeños					polares			básicos			ácidos	
		I	V	L	F	M	W	Y	C	A	G	P	S	T	N	Q	H	K	R	D	E	
I		4	3	2	0	1	-3	-1	-1	-1	-4	-3	-2	-1	-3	-3	-3	-3	-3	-3	-3	
V		3	4	1	-1	1	-3	-1	-1	0	-3	-2	-2	0	-3	-2	-3	-2	-3	-3	-2	
L		2	1	4	0	2	-2	-1	-1	-1	-4	-3	-2	-1	-3	-2	-3	-2	-2	-4	-3	
F		0	-1	0	6	0	1	3	-2	-2	-3	-4	-2	-2	-3	-3	-1	-3	-3	-3	-3	
M		1	1	2	0	5	-1	-1	-1	-1	-3	-2	-1	-1	-2	0	-2	-1	-1	-3	-2	
W		-3	-3	-2	1	-1	11	2	-2	-3	-2	-4	-3	-2	-4	-2	-2	-3	-3	-4	-3	
Y		-1	-1	-1	3	-1	2	7	-2	-2	-3	-3	-2	-2	-2	-1	2	-2	-2	-3	-2	
C		-1	-1	-1	-2	-1	-2	-2	9	0	-3	-3	-1	-1	-3	-3	-3	-3	-3	-3	-4	
A		-1	0	-1	-2	-1	-3	-2	0	4	0	-1	1	0	-2	-1	-2	-1	-1	-2	-1	
G		-4	-3	-4	-3	-3	-2	-3	-3	0	6	-2	0	-2	0	-2	-2	-2	-2	-1	-2	
P		-3	-2	-3	-4	-2	-4	-3	-3	-1	-2	7	-1	-1	-2	-1	-2	-1	-2	-1	-1	
S		-2	-2	-2	-2	-1	-3	-2	-1	1	0	-1	4	1	1	0	-1	0	-1	0	0	
T		-1	0	-1	-2	-1	-2	-2	-1	0	-2	-1	1	5	0	-1	-2	-1	-1	-1	-1	
N		-3	-3	-3	-3	-2	-4	-2	-3	-2	0	-2	1	0	6	0	1	0	0	1	0	
Q		-3	-2	-2	-3	0	-2	-1	-3	-1	-2	-1	0	-1	0	5	0	1	1	0	2	
H		-3	-3	-3	-1	-2	-2	2	-3	-2	-2	-2	-1	-2	1	0	8	-1	0	-1	0	
K		-3	-2	-2	-3	-1	-3	-2	-3	-1	-2	-1	0	-1	0	1	-1	5	2	-1	1	
R		-3	-3	-2	-3	-1	-3	-2	-3	-1	-2	-2	-1	-1	0	1	0	2	5	-2	0	
D		-3	-3	-4	-3	-3	-4	-3	-3	-2	-1	-1	0	-1	1	0	-1	-1	-2	6	2	
E		-3	-2	-3	-3	-2	-3	-2	-4	-1	-2	-1	0	-1	0	2	0	1	0	2	5	

Score de BLOSUM62



-4 -2 0 2 4 ≥ 6

■ Hidrofóbico ■ Polar ■ Ácido ■ Básico ■ Especial

ACGTGGAT-ACI
ACG-GAATGACT

The diagram illustrates a pairwise alignment between two DNA sequences. The top sequence is 'ACGTGGAT-ACI' and the bottom sequence is 'ACG-GAATGACT'. Two vertical orange boxes highlight the aligned regions: the first box contains 'G' from the top sequence and 'G' from the bottom sequence; the second box contains 'G' from the top sequence and 'A' from the bottom sequence. Small orange lines extend from the bottom of these boxes, suggesting further alignment or continuation of the sequences.


Alineamiento por pares (Pairwise alignment)

...

Homología no es similitud

Similitud es una medida. Se cuenta: qué fracción de las posiciones coincide entre dos secuencias. Es un número continuo y es un hecho observable.


Homología es una afirmación histórica: que dos secuencias descienden de una secuencia ancestral común. No es un número. Es sí o no. Y no se observa nunca, porque el ancestro no está aquí; se infiere.



Un alineamiento es una hipótesis

Un alineamiento de dos secuencias es una matriz de dos renglones, uno por secuencia, donde se pueden insertar guiones para que ambos queden del mismo largo. Cada columna afirma algo: que esos dos residuos descienden de la misma posición ancestral, o que hubo una inserción o delección.

				115					120					125					
Sequence A	A	G	T	T	G	A	C	T	T	C	T	C	A	G	G	T	A	T	T
Sequence B	A	G	G	T	A	A	C	T	T	C	A	G	A	T	G	A	A	A	T
Sequence C	A	G	G	T	C	A	C	-	-	G	A	C	A	G	G	C	A	T	T
Sequence D	A	G	G	T	C	A	C	-	-	G	A	C	A	G	G	C	A	-	T
Sequence E	A	G	G	T	C	A	C	T	T	G	A	G	A	-	G	C	A	-	T
Sequence F	A	G	G	T	C	A	C	T	T	G	A	C	A	G	G	C	A	T	T
Consensus	A	G	g	T	c	A	C	t	t	g	a	c	A	g	G	c	A	t	T



1. Distancia Hamming

Empecemos por “qué tan parecidas son dos cadenas”: contar en cuántas posiciones difieren.

Es la distancia de Hamming, y la definió Richard Hamming en 1950 en los laboratorios Bell, trabajando en códigos que detectaran y corrigieran errores de transmisión.

Sin desplazar

S	E	L	E	C	T	I	V	A
x	x	x	x	x	x	x	x	x
E	L	E	C	T	I	V	A	S

Distancia de Hamming = 9




un solo hueco de cada lado

Desplazando una posición

S	E	L	E	C	T	I	V	A	-
-	E	L	E	C	T	I	V	A	S

8 coincidencias de 10

Las dos cadenas son la misma, corrida un lugar. Arriba, 9 columnas y ninguna coincide; abajo, con un hueco de cada lado, 8 de 10.



2. La subcadena común más larga

SEQ1 L E C



SEQ2 S E L E C T I V A

El problema con exigir contigüidad es que es demasiado frágil. Una sola mutación puntual en medio de una región idéntica de 200 bases parte la subcadena común en dos de 100. Y dos genes que comparten tres exones conservados separados por intrones divergentes no tienen ninguna subcadena común larga, aunque su parentesco sea evidente.



3. Contar k-mers compartidos



Si la contigüidad larga es demasiado exigente, contemos palabras cortas: cuántas subcadenas de longitud k comparten las dos secuencias.



El juego de emparejar símbolos

Hamming falló por no admitir huecos. La subcadena falló por exigir contigüidad. Los k-mers fallaron por perder el orden. Lo que necesitamos entonces es algo que admita huecos, no exija contigüidad y conserve el orden.

El objetivo del juego: emparejar la mayor cantidad posible de símbolos idénticos.




4. El bueno: la subsecuencia común más larga

Una subsecuencia de una cadena es lo que queda al borrar cero o más símbolos, conservando el orden de los que quedan pero sin exigir que sean contiguos. ACT es subsecuencia de AxCyTz.

Subcadena y subsecuencia no son lo mismo y se confunden todo el tiempo. Subcadena: contigua. LECT en SELECTIVA. Subsecuencia: en orden, no necesariamente contigua. SELVA en SELECTIVA.


Ahora la observación que amarra todo: los símbolos emparejados en un alineamiento forman una subsecuencia común de las dos secuencias. Y maximizar los símbolos emparejados es, exactamente, encontrar la subsecuencia común más larga.



Un rodeo por Manhattan

No funciona. Y no funciona de manera instructiva: una cuadra gorda al principio puede meterlos por un camino que después se queda sin nada, mientras la ruta que empezó modesta desemboca en un tramo lleno de atracciones (Figura 2).

Lo óptimo localmente no es lo óptimo globalmente. Escriban eso. Es la razón de fondo por la que hace falta un método más listo que la intuición.



Alineamiento como camino en un DAG



Grafo dirigido acíclico

Ahora las flechas, que son exactamente las tres jugadas del juego:

La diagonal, de $(i-1, j-1)$ a (i, j) : consumo un símbolo de cada secuencia y los alinea. Es una coincidencia o una discrepancia.

La horizontal, de $(i, j-1)$ a (i, j) : consumo un símbolo de w solamente. Hueco en v .

La vertical, de $(i-1, j)$ a (i, j) : consumo un símbolo de v solamente. Hueco en w .



Por qué no se puede a mano

Falta una pregunta obvia: ya que sabemos qué buscamos, por qué no probamos todos los caminos y nos quedamos con el mejor?

Porque son demasiados.

El número de alineamientos posibles de dos secuencias de longitud n , donde los huecos nunca se emparejan con huecos, es el coeficiente binomial $C(2n, n)$, que crece aproximadamente como 2^{2n} dividido entre la raíz de πn

Los números:


Longitud Alineamientos posibles

11 705,432

100. cerca de 10^{59}

300 del orden de 10^{179}

Encontrar la subsecuencia común más larga de dos secuencias es equivalente a encontrar el camino de mayor peso en el grafo de alineamiento.



Actividad 2.

- **Alineamiento o grafo.**

1. Ejemplo de Manhattan

Quiz_5_ENES

Dar tiempo para explorar archivos y realizar Quiz

25 de septiembre de 2026

